

文本分类实现 实验报告

在 NYT 新闻三分类任务上，系统比较词袋模型、Word2Vec / GloVe 词向量与 BERT 预训练语言模型三类文本表示方法，统一在相同的 80/10/10 数据划分上，以 Accuracy 与 Macro-F1 两项指标进行评价与分析。

姓名：吴嘉豪 · 学号：2113454 · 2026 年 9 月

目录

1 实验概述	3
2 数据集与预处理	3
2.1 数据划分	3
2.2 分词	4
3 Task 1: Bag of Words + Logistic Regression	4
4 Task 2: 词向量 + Logistic Regression	4
4.1 定性检查: 最近邻词	5
4.2 分析	5
5 Task 3: BERT 微调	6
5.1 分析	6
6 总体比较与讨论	6
7 结论	8
附录 A 复现说明	8
附录 B 代码结构	9

1 实验概述

本实验在 New York Times (NYT) 新闻数据集上完成文本分类任务。数据集包含 business、politics、sports 三个类别，类别分布不均衡 (sports 约占 75%)。实验分别使用三类文本表示方法训练分类器，并在完全相同的数据划分上比较性能：

- 词袋模型 (Task 1, 30 分)**：Binary Bag-of-Words 与 Word Frequency 两种稀疏表示 + Logistic Regression；
- 词向量 (Task 2, 50 分)**：预训练 GloVe (6B, 100d)、AG News 自训练 Word2Vec 与 NYT 自训练 Word2Vec，文档向量取词向量平均 + Logistic Regression；
- 预训练语言模型 (Task 3, 20 分)**：微调 bert-base-uncased, max_length=64, 3 epochs。

评价指标为 Accuracy 与 Macro-F1。由于类别不均衡，少数类 (business / politics) 的识别能力在 Accuracy 中容易被掩盖，Macro-F1 通过对各类别 F1 取平均提供更公平的度量。

实验环境

项目	配置
操作系统 / 硬件	Windows 10 • NVIDIA RTX 3050 Laptop 4GB
Python / 核心库	Python 3.12 • scikit-learn 1.9 • gensim 4.4 • nltk 3.10
深度学习框架	PyTorch 2.14 (CUDA 12.6) • transformers 5.17
BERT 训练设置	fp16 混合精度 • batch size 16

表 1 实验环境与主要依赖

2 数据集与预处理

NYT 数据集共 11,519 篇新闻 (text + label 两列)，作为分类主数据集；AG News 数据集共 90,000 篇文本 (仅 text 一列，无标签)，仅用于 Task 2 中训练 Word2Vec 词向量。

2.1 数据划分

对 NYT 全量数据以固定随机种子 (random_state=42) 随机打乱后，按 80% / 10% / 10% 划分训练集、验证集与测试集。划分采用分层抽样，保持各类别比例一致；划分结果落盘保存，所有实验加载同一份数据，保证方法间的可比性。验证集仅用于超参数选择 (如 BERT 学习率)，测试集仅用于最终性能报告。

NYT 数据划分 (分层，随机种子 42)

划分	样本数	business	politics	sports
Training	9,215	1,143	1,161	6,911
Validation	1,152	143	145	864
Test	1,152	143	145	864

表 2 NYT 数据集 80/10/10 划分及类别分布

2.2 分词

全流程统一使用 `nltk.word_tokenize` 分词：先小写化，再仅保留纯字母 token（去除数字与标点，这类 token 无对应词向量且对分类贡献很小）。同一分词方案用于 BoW 词表构建、Word2Vec 训练语料与文档向量计算，保证各方法输入一致。

3 Task 1: Bag of Words + Logistic Regression

从训练集构建词表， $|V| = 57,275$ 。每篇文档表示为 $|V|$ 维向量，两种表示的区别仅在于分量取值：Binary BoW 记录词是否出现（x 取 0/1），Word Frequency 记录词出现次数。两种表示均以 `scikit-learn CountVectorizer` 实现（`binary=True/False`），分类器统一为 `LogisticRegression (max_iter=1000)`。

Task 1 结果 (NYT Test Set)

表示方法	Accuracy	Macro-F1
Binary BoW	0.9905	0.9775
Word Frequency	0.9913	0.9817

表 3 两种词袋表示的分类性能

分析：两种 BoW 表示均达到约 99% 的准确率，说明该任务中“哪些词出现”本身就是极强的分类信号（如 `sports` 类的 `team`、`game`、`season` 等高判别性词汇）。词频版略优于二值版，说明出现次数提供了额外的强度信息。但新闻文本中多数词仅出现一次，因此两者差距很小（Accuracy 相差 0.0008）。

4 Task 2: 词向量 + Logistic Regression

统一使用 100 维词向量；文档向量 = 文档内所有有效单词词向量的平均（测试集中不存在完全无词表命中的退化样本）。三组实验的区别仅在词向量来源：

1. 预训练 GloVe: 官方 glove.6B.100d.txt (400,000 词, 60 亿词符语料训练);
2. Word2Vec (AG News): gensim Word2Vec, vector_size=100、window=5、min_count=5、CBOW、5 epochs, 在 AG News 全量 90,000 篇上训练;
3. Word2Vec (NYT): 同超参数, 仅在 NYT 训练集 (9,215 篇) 上训练, 严格将验证与测试数据排除在一切训练过程之外。

Task 2 结果 (NYT Test Set)

文档表示	Accuracy	Macro-F1
GloVe 6B 100d (预训练)	0.9800	0.9526
Word2Vec 训练于 AG News	0.9792	0.9500
Word2Vec 训练于 NYT	0.9809	0.9540

表 4 三种词向量文档表示的分类性能

4.1 定性检查: 最近邻词

对两个自训练 Word2Vec 模型查询典型词的最近邻, 可以直观看出训练语料领域的影响:

Word2Vec 最近邻对比 (余弦相似度)

查询词	W2V-AG News 最近邻	W2V-NYT 最近邻
president	administration, leader, dushanbe, voltchkov	chairman, secretary, chairwoman, adviser, barack
baseball	franchise, owners, nfl, selig	mlb, rivera, rodriguez, yankees
economy	economic, recovery, inflation, growth, currency	growth, inflation, economic, market, crisis

表 5 两个自训练 Word2Vec 模型的最近邻词

4.2 分析

平均词向量方法整体比 BoW 低约 1 个百分点。平均操作把整篇文档压缩成 100 维, 抹平了词序与关键词的尖峰信号; BoW 的 57,275 维稀疏向量则保留了每个判别性词汇的独立权重, 而 Logistic Regression 恰好擅长利用这种稀疏线性结构。

W2V-NYT 的训练语料只有 AG News 的约 1/10, 分类性能却略高一些。从表 5 的最近邻看, NYT 训练出的向量更贴近该数据集自身的时政与体育词汇, barack、yankees 等正是本任务的强判别词; AG 语料以短财经、体育快讯为主, 向量里混进了网球选手这类与 NYT 无关的实体。对平均池化来说, 语料的词分布与下游任务是否接近, 比语料规模的影响更大。

预训练 GloVe 的表现与 NYT 自训练的 Word2Vec 基本持平 (Macro-F1 相差 0.0014)。GloVe 的训练语料大了两个数量级，但并不偏向 NYT 的词汇分布，规模优势没有体现出来，与上面的观察一致。

5 Task 3: BERT 微调

以 `AutoModelForSequenceClassification` 加载 `google-bert/bert-base-uncased` (12 层、768 维、约 1.1 亿参数) 并接三分类头。Tokenization 设 `max_length=64` 并截断，训练时以 `DataCollatorWithPadding` 按 batch 动态补齐。训练共 3 个 epoch, batch size 16, 采用 AdamW 优化器与线性 warmup 调度, 并以 fp16 混合精度训练。学习率按 BERT 论文推荐值在验证集上从 $\{2e-5, 3e-5\}$ 中选择。

Task 3 结果：学习率选择与最终性能

学习率	Val Accuracy	Val Macro-F1	Test Accuracy	Test Macro-F1
2e-5	0.9792	0.9530	0.9844	0.9657
3e-5 (选用)	0.9800	0.9553	0.9844	0.9676

表 6 BERT 微调学习率对比 (最终模型按验证集 Macro-F1 选出)

5.1 分析

训练损失在 3 个 epoch 内降到 0.01 左右，基本记住了训练集。微调后 BERT 的 98.44% 准确率高于三种平均词向量方法 (97.9% - 98.1%)，说明上下文相关的表示和端到端微调确实带来了提升：注意力可以聚焦关键短语，而不是被大量次要词的平均稀释。

测试集错误集中在 politics 类 (recall 约 0.92 - 0.96) ——该类与 business 共享大量经济政策词汇，是三个类别中最难区分的一对。在 9,215 篇的小训练集上，BERT 未超过 BoW + LR 基线 (99.13%)；学习率从 $2e-5$ 提高到 $3e-5$ 仅带来 0.002 的 Macro-F1 提升，说明模型已接近数据量约束下的上限。此外，作业固定要求 `max_length=64`，对 NYT 长文本存在信息截断，也是其相对 BoW 的一个不利因素。

6 总体比较与讨论

全部 7 组实验在相同数据划分上的测试集性能汇总如下图与下表：




图 1 七组实验的 Test Accuracy 与 Macro-F1 对比

全部实验汇总（NYT Test Set, 相同 80/10/10 划分）

实验设置	Accuracy	Macro-F1
Task1: Binary BoW + LR	0.9905	0.9775
Task1: Word Frequency + LR	0.9913	0.9817
Task2a: GloVe 6B 100d（平均）+ LR	0.9800	0.9526
Task2b: Word2Vec（AG News 训练，平均）+ LR	0.9792	0.9500
Task2c: Word2Vec（NYT 训练，平均）+ LR	0.9809	0.9540
Task3: BERT 微调（lr=2e-5）	0.9844	0.9657
Task3: BERT 微调（lr=3e-5，最终）	0.9844	0.9676

表 7 全部实验的性能汇总（最优值加粗）

效果最好的仍然是最简单的词袋表示。这个任务里每类都有大量强特征词，类别间接近线性可分，BoW 加 Logistic Regression 因此很难被超越。深度模型的优势需要足够多的训练数据才能发挥，本任务的训练集只有 9,215 篇。

三组词向量实验的结果非常接近，瓶颈应该在平均池化这种表示方式本身：求平均时会丢失词序和关键句的信息，静态向量也处理不了多义词，换不同的训练语料带来的改善有限。

BERT 微调超过了全部三组平均词向量方法，是表现最好的神经方法，但仍没有超过线性基线，这与文献中“强线性基线难以击败”的观察相符。

所有方法的 Accuracy 都比 Macro-F1 高 1 到 3 个百分点，差距来自 sports 占约 75% 的类别不均衡：多数类的正确预测抬高了 Accuracy，而少数类的少量错误在 Macro-F1 中被明显放大，

所以评价这类数据时两项指标都要看。

7 结论

1. Word Frequency + Logistic Regression 取得了最好的结果 (Accuracy 0.9913 / Macro-F1 0.9817)，Binary BoW 紧随其后。对这个线性可分性较好的新闻分类任务，稀疏词袋特征已经足够有效。
2. 三种词向量文档表示性能相近，整体比 BoW 低约 1 个百分点；其中在规模小得多的 NYT 语料上训练的 Word2Vec 反而优于 AG News 语料训练的版本，说明语料与任务的匹配程度比规模更重要。
3. BERT 微调 (Accuracy 0.9844 / Macro-F1 0.9676) 是最好的神经方法，说明预训练模型对上下文语义的建模有价值，但在本数据规模上没有超过线性基线。
4. Accuracy 与 Macro-F1 的差距来自类别不均衡，少数类的错误对 Macro-F1 影响更大，评价不均衡数据时两项指标都应报告。

附录 A 复现说明

完整代码与依赖清单见 `hw1/` 目录与仓库根目录 `requirements.txt`，运行说明见 `hw1/README.md`。以下命令均在 `hw1/` 目录下执行：

```
python src/data_prep.py # 生成固定数据划分
python src/task1_bow.py # Task 1: Binary BoW / Word Frequency + LR
python src/task2_word2vec.py # Task 2b/2c: Word2Vec(AG / NYT) + LR
python src/task2_glove.py # Task 2a: GloVe 6B 100d + LR
python src/task3_bert.py --lr 3e-5 # Task 3: BERT 微调 (学习率可选)
python src/aggregate_results.py # 汇总 results/results.csv
```

GloVe 下载自 <http://nlp.stanford.edu/data/glove.6B.zip> (解压出 `glove.6B.100d.txt` 放入 `data/` 目录)；BERT 权重已本地缓存于 `models/bert-base-uncased/`；NLTK 分词数据需一次性 `nlk.download("punkt")` 与 `nlk.download("punkt_tab")`。

附录 B 代码结构

本仓库按作业组织：每次作业独立放在 hw1/、hw2/ 等文件夹中，互不干扰。hw1/ 内 src/common.py 提供共享工具（数据加载、分词、平均池化、评估与结果落盘），保证各任务使用完全相同的数据划分与评价流程；data_prep.py 生成并落盘 80/10/10 划分；各 task 脚本分别实现对应任务；aggregate_results.py 汇总所有实验指标（hw1/results/results.csv）。hw1/data/raw/ 存放原始数据，hw1/report/ 存放本报告。